

# KRY 1. Projekt

Andrej Zaujec

April 4, 2021

## Contents

<b>1</b>	<b>Úvod</b>	<b>1</b>
<b>2</b>	<b>Hlavný modul</b>	<b>1</b>
<b>3</b>	<b>Kasiski modul</b>	<b>2</b>
<b>4</b>	<b>Ngram modul</b>	<b>3</b>
<b>5</b>	<b>Friedman modul</b>	<b>3</b>
<b>6</b>	<b>KeyFinder modul</b>	<b>3</b>

## 1 Úvod

Cielom projektu je vykonanie Friedmanovho a Kasiskeho testu nad textom zašifrovaným Vigenеровou šifrou, následne zvoliť vhodnú dĺžku kľúča a taktiež zistiť použitý kľúč. Dokumentácia je rovnako logicky členená ako samotný kód. V jednotlivých kapitolách sú popísané zjednodušene jednotlivé moduly a taktiež rozhodnutia, ktoré boli počas implementácie vykonané.

## 2 Hlavný modul

Hlavný modul alebo taktiež nazývaný main, má za úlohu tieto kroky.

- Prečítať vstup
- Očistiť vstupný reťazec zmazaním všetkých znakov okrem znakov anglickej abecedy

- Spustiť Friedmanov test nad očistením reťazcom
- Spustiť Kasiskeho test nad očistením reťazcom
- Na základe výsledkov predchádzajúcich testov sa rozhodnúť pre správnu dĺžku kľúča
- Uhádnuť kľúč volaním triedy KeyFinder
- Vypísanie všetkých získaných hodnôt na štandardný výstup

Najzaujímavejšou činnosťou tohoto modulu je zvolenie čo najsprávnejšieho kľúča, ktoré spočíva v nasledujúcich krokoch. Program sa pozrie na 10 najčastejších deliteľov získaných z Kasiskeho testu, získanie týchto deliteľov bude viacej popísané v kapitole 3. Následne tieto delitele považuje za možné dĺžky kľúča. Každá vhodná dĺžka kľúču musí byť maximálne dva krát tak veľká ako výsledok Friedmanovho testu. Toto rozhodnutie plyní z mojej skúsenosti počas testovania kedy pri neobmedzenej možnej dĺžke sa duplikovaná kľúč na základe IC(Index of coincidence) javil ako vhodnejší kandidát než samotný správny, kratší kľúč. Zároveň táto podmienka má aj svoje obmedzenie a to je prípad kedy je kľúč príliš dlhý a Friedmanov test dva krát menší, v takomto prípade nebude správny kľúč nájdený. Zo spomínaných 10 kandidátov, ktorý sú kratší ako dvojnásobok Friedmanovho testu sa pre každý spočíta IC pre  $k$  podreťazcov, kde  $k$  je dĺžka kľúča a následne sa tieto IC spriemerujú a kľúč, ktorý má tento priemer najväčší je považovaný za najvhodnejšieho kandidáta na dĺžku kľúča.

### 3 Kasiski modul

Ako už názov modulu naznačuje, tento modul je zameraný na výpočet Kasiskeho testu. Implementácia je na základe rozkladu vzdialeností opakujúcich sa ngramov na najčastejšie vyskytujúcich deliteľov. Tvorenie ngramov a počítanie ich výskytov a vzdialeností má na starosť modul Ngram popísaný v 4 kapitole. Dĺžky ngramov sú 4,5,6,7. Tieto veľkosti sa javili ako najoptimálnejšie počas testovania a trigramy som vylúčil pretože už boli viac krát zahrnuté v spomínaných dĺžkach ngramov a neprinášali žiadnu informáciu navyše. Výsledok Kasiskeho modulu je v mojom prípade zoznam dvojíc, kde prvý prvok dvojice je daný deliteľ a druhý prvok je počet jeho výskytov. Tento zoznam je zoradený podľa najčastejších výskytov deliteľov to znamená podľa druhého prvku. Ako celkový výsledok Kasiskeho testu volím najčastejšie vyskytujúceho deliteľa okrem čísla dva. Toto číslo som usúdil,

ako priveľmi krátke na to aby bolo kľúčom a veľmi často sa objavovalo ako najčastejší deliteľ. Jedným z pozorovaných problémov tohoto prístupu je nie vždy vhodná voľba správneho kľúča pretože väčšie kľuče sa častokrát predbežované svojimi menšími deliteľmi a teda za výsledok sa zvolí len nejaký menší deliteľ správneho kľúču.

## 4 Ngram modul

Tento modul slúži na výpočet ngramov zo zadaného textu a je používaný iba Kasiski modulom. Podstatou výpočtu ngramov je rozdelenie textu na ngramy o určitej dĺžke a následne sa frekvencia ngramov porovnáva s prievazaným zoznamom. Každý záznam v tomto previazanom zozname reprezentuje jeden ngram, počet výskytov daného ngramu a taktiež aj uchovanie vzdialeností rovnakého ngramu vo vstupnom texte. Previazaný zoznam je optimalizovaný, aby čo najčastejšie opakujúce ngramy radil na svoj začiatok.

## 5 Friedman modul

Daný modul je zameraný na výpočet Friedmanovho testu nad daným reťazcom. Výpočet kľúča s dĺžkou  $k$  je daný vzorcom.

$$k = \frac{k_p - k_r}{k_0 - k_r}$$

$$k_0 = \frac{\sum_{i=1}^c n_i(n_i - 1)}{N(N - 1)}$$

$$k_r = 0.0385$$

$$k_p = 0.067$$

Kde  $n_i$  je výskyt daného písmena v reťazci a  $N$  je veľkosť reťazca. Pričom konštanty  $k_p$  a  $k_r$  sú vhodne zvolené pre anglický monocase text. Ich dôsledný význam je možné nájsť na stránke zdroja samotného vzorca.

## 6 KeyFinder modul

Tento modul dokáže nájsť heslo pre daný reťazec a správne zvolenú dĺžku kľúča  $k$ . Princíp hľadania kľúča spočíva v rozdelení si reťazcu na  $k$  podreťazcov pričom znak na indexe  $n$  bude patriť do  $n \pmod k$  podreťazcu pričom podreťazce označujeme od 0 po  $k - 1$ . Po tomto rozdelení už stačí

vyriešiť monoalfabetickú šifru nad každým podreťazcom pomocou nájdenie správneho posunu. Tento posun sa dá nájsť skrz vzorec.

$$M_g = \sum_{i=0}^{25} \frac{p_i f_{i+g}}{n}$$

Kde  $p_i$  je pravdepodobnosť písmena v danom jazyku,  $f_{i+g}$  sú frekvencie písmen anglickej abecedy v danom reťazci pričom  $g$  je spomínaný vhodný posuv. Hodnota  $M_g$  by sa v bežnom anglickom texte mala blížiť k 0.065. V tomto prípade spravím cyklus v cykle(skrz všetky posuvy a všetky písmená) a posuv, ktorú mi zaručil najbližšiu hodnotu  $M_g$  k 0.065 reprezentuje jedno písmeno kľúča anglickej monocase abecedy. Tento postup modul opakuje pre každý podreťazec a za predpokladu, že poznáme správnu dĺžku kľúča a zašifrovaný text je anglický a je používaný v bežnej reči tak sme získali kľúč k správe zašifrovanej Vigenorovou šifrou. Zdroj vzorca a postupu je prednáška.